

Treniranje umjetne inteligencije: znanost i podaci

Projekt SmAlle

Ključne informacije

Ciljna skupina: 8 - 12 godina.

Trajanje aktivnosti: 4–5 nastavnih sati (po 45 min)

Glavni ciljevi učenja:

1. **Učenje stroja:** Razumijete obuku, testiranje i skupove podataka.
2. **Znanstveno istraživanje:** Prikupljanje i označavanje podataka iz stvarnog svijeta (obraznički znakovi).
3. **Etika:** Identificirajte pristranost i ograničenja u modelima AI-a.
4. **Zajednica:** Podjela podataka na međunarodnom nivou eTwinning.

Ishodi učenja

Do kraja projekta učenici će moći:

ZNANJE I RAZUMIJEVANJE:

- Opisajte kako strojno učenje funkcionira (trening/testiranje).
- Razumijete primjene AI-a u prepoznavanju slika.
- Upoznajte etičke razloge kao što su povjerenje i odgovornost.

VJEŠTINE I SPOSOBNOSTI:

- Upotreba Teachable Machine stvoriti modele AI-a.
- Prikupiti, označiti i organizirati skupove podataka.
- Analizirajući AI pogreške u poređenju s ljudskim razumom.

STAVOVI I VRIJEDNOSTI:

- Cijenite kombinaciju ljudskog uvida i tehnologije.
- Pokazati otvorenost za različite kulturne perspektive.

Europska dimenzija / povezanost s programom Erasmus+

- **Demokratija i uključivanje:** Sličan doprinos zajedničkim skupovima podataka
- **Kulturna svijest:** Prilagodba umjetne inteligencije regionalnim razlikama (npr.

prometnim znakovima).

- **Digitalna odgovornost:** Učenje GDPR-a i etičke uporabe podataka.

1. Resursi i alati

- **Digitalni alati:** Teachable Machine, eTwinning/TwinSpace, Padlet.
- **Računarski materijal:** Tablete/Kamere, Laptopi.
- **Potrebni materijali:** AI-generirane fotografije lica (Att 1.1), slike prometnih znakova.

Korisne poveznice:

- [Teachable Machine](#)
- [Video o klasifikaciji slika](#)
- [Članak Chihuahua vs Muffin](#)
- [Teachable Machine stranica za obuku](#)

Materijali za podršku nastavi:

- Upotreba nastavničke rubrike i digitalnih formulara za refleksiju, kao što su: Google Forumi ili Microsoft Forms, nakon testiranja i rasprave o modelima.

Pregled aktivnosti

Aktivnost	Trajanje	Opis
Uvod	20 min	Motivacija: Gledajući AI "bloopers" (poznavanje ne uspije). Razgovor o tome zašto AI čini greške.
1	45 minuta	Mnogo lica: Klasificiranje lica bez tehnologije. Razgovarajući o ljudskom vs. mašinska percepcija.
2	45 minuta	Znakovi prometa: Zbiram fotografije lokalnih znakova. Kategorizacija i upload na eTwinning.
3	45 minuta	Obuka: Upotreba Teachable Machine Da treniram modelku. Testiranje sa međunarodnim slikama.
4	45 minuta	Etika: Debata "Može li AI zamijeniti ljude?" Analiziranje grešaka. Razmišljaj.

2. Uvod: AI neuspjehi

Cilj: Shvaćam da AI nije savršen.

- **Video:** "Smiješno prepoznavanje predmeta ne uspijeva".
- **Razgovor:** "Koja te greška iznenadila?"
- **Koncept:** AI je dobar samo kao i podaci koje mu daješ.

3. Aktivnost 1. - Mnogi lica, jedan svijet

Cilj: Uporedi ljudsko i mašinsko vidje.

- **Zadatak:** Grupne fotografije različitih ljudi na temelju kriterija.
- **Razgovor:** Ljudi vide "kulturu" ili "rod"; Mašina vidi "pixe" i "oblike".

4. Aktivnost 2: Proučavanje prometnih znakova

Cilj: Zbirka podataka.

- **Rad na terenu:** Fotografija lokalnih prometnih znakova.
- **Zajednica:** Upload na eTwinning u partnerskim školama.
- **Analiza:** Jesu li znakovi "Stop" isti u svim zemljama?

5. Aktivnost 3: Osposobljavanje modela AI-a

Cilj: Praktično strojno učenje.

- **Ruke:** Teachable Machine.
- **Korak 1:** Osnivanje razreda (npr. "Znakovi upozorenja", "Regulativni znakovi").
- **Korak 2:** Upload slike i vlak.
- **Korak 3:** Test s znakom iz partnerske zemlje. Je li uspješno?

6. Aktivnost 4: Etika i razmišljanje

Cilj: Kritičko razmišljanje.

- **Razgovor:** "Može li AI zamijeniti laboratorijskog znanstvenika?"
- **Razmišljanje:** Razgovarajte o Padlet.
- **Izlaz:** Digitalna refleksija o važnosti ljudskog suđenja.