

Treniranje umjetne inteligencije: znanost i podaci

Projekt SmAlle

Ključne informacije

Ciljna skupina: 13 - 16 godina

Trajanje aktivnosti: 4–5 nastavnih sati (po 45 min)

Glavni ciljevi učenja:

1. **Znanstveno razložnje:** Dublje razumijevanje koncepata klasifikacije pomoću AI-a.
2. **Kritičko mišljenje:** Oceniti ograničenja AI-a i ulogu ljudskog suđenja.
3. **Digitalna pismenost:** Modeli vlakova koji koriste Teachable Machine i analizirati kvalitetu podataka.
4. **Etička svijest:** Razmislite o implikacijama AI-a u znanstvenom kontekstu.

Ishodi učenja

Do kraja projekta učenici će moći:

ZNANJE I RAZUMIJEVANJE:

- Opisati koncepte strojnog učenja (školjenje, testiranje, skupovi podataka).
- Identificirati izvore pogrešaka i pristranosti u modelima AI-a.
- Upoznajte etičke razloge kao što su povjerenje i odgovornost.

VJEŠTINE I SPOSOBNOSTI:

- Skupljanje i označavanje skupova podataka učinkovito.
- Upotreba Teachable Machine stvaranje predviđenih modela.
- Zajednici u timovima za dizajniranje eksperimenata i analizu rezultata.

STAVOVI I VRIJEDNOSTI:

- Cijenite sinergiju između ljudskog uvida i tehnologije.
- Pokazati otvorenost za različite perspektive u znanstvenim raspravama.

Europska dimenzija / povezanost s programom Erasmus+

- **Znanstveno državljanstvo:** Učestvovanje u znanstvenim istraživanjima i raspravama u stvarnom svijetu.



- **Digitalna odgovornost:** Promicanje etičkih praksi podataka.
- **Zajednica:** Mogućnosti za dijeljenje skupova podataka s europskim vršnjacima.

1. Resursi i alati

- **Digitalni alati:** Teachable Machine, eTwinning, Padlet.
- **Računarski materijal:** Računari/tablete s web kamerama.
- **Potrebni materijali:** Prirodni materijali za klasifikaciju (kamene, lišća itd.), radni listovi.

Korisne poveznice:

- [Teachable Machine](#)
- [Video o računalnom vidanju i klasifikaciji](#)
- [Članak Chihuahua vs Muffin](#)
- [Teachable Machine Tutorial](#)

Materijali za podršku nastavi:

- Pripremajte radni list, rubricu ocjene i obrazac za ocjenu međuvremenih, opcionalno upotrebom Google Obrazac ili Microsoft Forms.
- U početnoj klasifikaciji uključite štampane primjerke ili primjerke predmeta.

Pregled aktivnosti

Aktivnost	Trajanje	Opis
Uvod	20 min	AI u znanosti: Razgovor o tome kako strojno učenje podržava znanstveno istraživanje.
1	45 minuta	Ljudski algoritam: Ručna klasifikacija predmeta za razumijevanje ljudskog procesa.
2	45 minuta	Prikupljanje podataka: Rad na terenu za snimanje i označavanje različitih slika za skup podataka.
3	45 minuta	Učenje modela: Upotreba Teachable Machine da treniraju i testiraju AI.
4	45 minuta	Etika i rasprava: "Može li umjetna inteligencija zamijeniti laboratorijske znanstvenice?" Kritična analiza i refleksija.

2. Uvod: AI u znanosti

Cilj: Kontekstualizujte AI kao alat.

- **Razgovor:** Kako AI prepoznaje zvijezdu ili stanicu?
- **Koncept:** Uči se iz ljudskih primjera.

3. Aktivnost 1: Ljudski algoritam

Cilj: Razumijete logiku klasifikacije.

- **Zadatak:** Učenici dobivaju skup predmeta (npr. različite stijene).
- **Akcija:** Stvorite pravila za njihovu ručno klasifikaciju.
- **Razmišljanje:** Kako si se odlučio? Koje osobine ste tražili?

4. Aktivnost 2: prikupljanje podataka

Cilj: Izgraditi robustni skup podataka.

- **Zadatak:** Timovi snimaju fotografije svoje dodijeljene kategorije.
- **Osredotočite se:** Kvalitet i raznolikost (svijetljenje, pozadina) kako bi se izbjegle predrasude.
- **Izlaz:** Map s označenim slikama.

5. Aktivnost 3: Uspostavljanje uzroka

Cilj: Praktično strojno učenje.

- **Ruke:** Teachable Machine.
- **Proces:** Učitati podatke → trenirati model → testirati.
- **Analiza:** Predstavite nove predmete. Da li ih AI prepoznaje? Identificirajte lažne pozitivne/negativne rezultate.

6. Aktivnost 4: Etika i rasprava

Cilj: Kritiko razmišljanje.

- **Tema rasprave:** "Može li AI zamijeniti ljudske laboratorijske znanstvenike?"
- **Razgovor:** Pouzdanost, odgovornost za greške i potreba za ljudskim nadzorom.
- **Ocijenivanje:** Učenici razmišljaju o svom učenju putem Padlet i obrazac povratne informacije.