

Uvod

Uče mašine da vide.

U ovoj radionici, učenici (13-16) istražuju raskrsnuće umjetne inteligencije i znanosti. Izgradom vlastitih skupova podataka i treninga za klasifikaciju znanstvenih objekata (kao što su stijene ili biljke), oni steknu praktično razumijevanje Machine Learning-a i etičkih izazova automatizacije.

Glavni ciljevi

- **Vlak:** AI modeli s prilagođenim podacima.
- **Analiza:** Znanstvena klasifikacija.
- **Razgovor:** AI vs. Ljudsko mišljenje.
- **Zajednici:** U istraživačkim timovima.

Resursi

- **Ruke:** Teachable Machine.
- **Platforma:** eTwinning.
- **Podaci:** Slike koje su sakupili učenici.
- **Tehnički:** Laptopi/tablete.
- **Podrška:** Radni list, rubrika, obrazac, primjerke kartica.



Osposobljavanje umjetne inteligencije

AI i strojno učenje



Co-funded by
the European Union

Sufinancira Europska unija.

Ciljna skupina: 13-16 godina
Projekt SmAlle

Ishodi učenja

Znanje:

- Proces mašinskog učenja.
- Izvori pristranosti u podacima.

Vještine:

- Stvaranje datoteka.
- Znanstveno istraživanje.

Vrijednosti

- Digitalna odgovornost.
- Kritiko razmišljanje.
- Znanstveni integritet.

1. Prikupljanje podataka

Rad na terenu: Učenici prikupljaju slike određenih znanstvenih kategorija (npr. magmatskih i sedimentnih stijena), vodeći računa o raznolikosti i kvaliteti podataka.

2. Osposobljavanje i testiranje

Teachable Machine: Učenici ulaze svoje podatke u alat za obuku modela. Zatim ga testiraju novim, nevidljivim uzorcima kako bi provjerili njegovu tačnost.

3. Etika

Razgovor: "Može li AI zamijeniti laboratorijske znanstvenike?" Učenici razgovaraju o pouzdanosti AI-a u kritičnim zadacima i važnosti ljudskog nadzora.

Razmišljanje: Padlet Razgovor o povjerenju u tehnologiju.